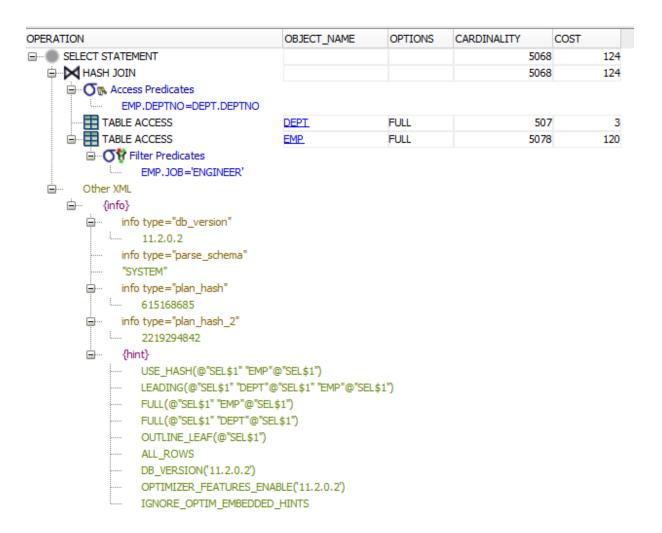
# Data Science e Tecnologie per le Basi di Dati

### Esercitazione 5 – Ottimizzatore di Oracle

# Query #1

```
SELECT /*+ FIRST_ROWS(n) */ *
FROM emp, dept
WHERE emp.deptno = dept.deptno AND emp.job = 'ENGINEER';
```

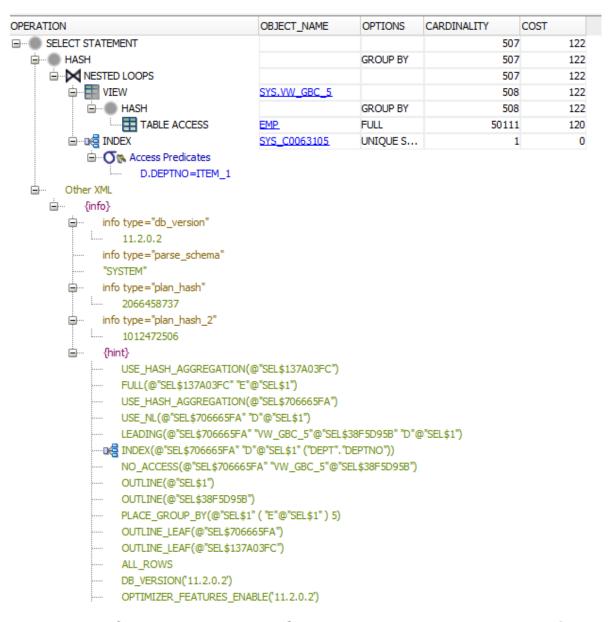


- Viene eseguita una **Hash Join** su DEPTNO, in seguito al **filtro** delle righe su attributo Job. Accesso alla tabella: full (= lettura di tutte le righe).
- Il costo rappresentato sulla colonna a destra è cumulativo. Questo incrementa infatti seguendo il percorso dalle foglie alla radice dell'albero del piano di esecuzione. Ad ogni operazione viene incrementato del costo di quest'ultima. In questo esempio le foglie dell'albero sono 2: i due table access su dept ed emp, con costo rispettivo 3 e 120. Salendo nell'albero i costi dei due accessi vengono sommati insieme al costo della Hash Join (3+120+1 = 124). La hash join ha infatti costo unitario.

### Confrontare i costi di hash join e nested loop usando l'hint USE / NO\_USE\_HASH

```
SELECT /*+ NO_USE_HASH(e d) */ d.deptno, AVG(e.sal)
FROM emp e, dept d
WHERE d.deptno = e.deptno
GROUP BY d.deptno;
```

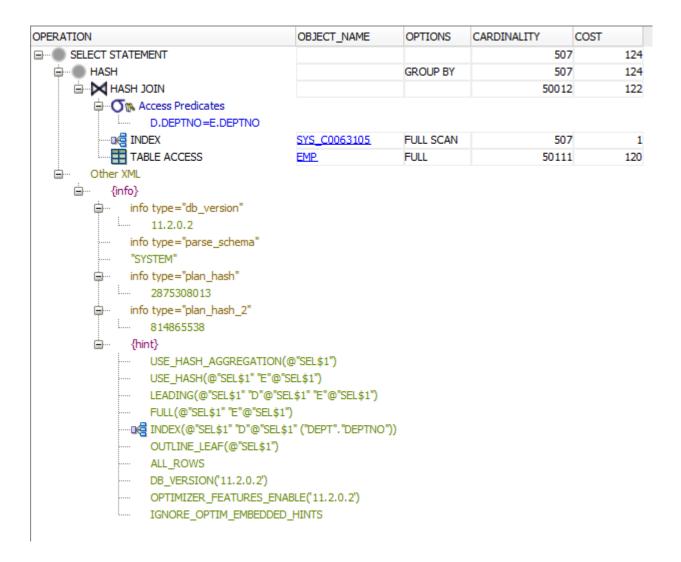
### Con hint NO\_USE\_HASH:



- DEPTNO = ITEM\_1: quando la Group By viene eseguita, si crea una vista in cui l'attributo chiave (DEPTNO) viene rinominato con ITEM\_1. ITEM\_1 diventa inoltre l'indice della vista per un accesso rapido ai gruppi.
- L'operazione di GROUP BY compare due volte. Quella più interna rappresenta l'anticipo della group by (anticipata prima della join). Quella più esterna rappresenta la Group By nella posizione iniziale, prima dell'anticipo. Infatti se si osserva il costo cumulativo, questo incrementa solo con la group by interna

(che svolge il lavoro) e non con quella esterna (che non deve più raggruppare in quanto i gruppi sono già stati creati da quella più interna).

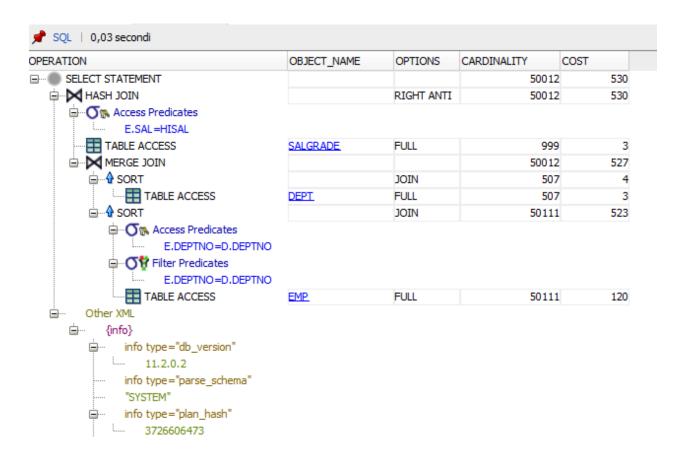
### **Con hint USE\_HASH:**



 Qui viene utilizzata una hash join. La group by invece non viene anticipata. Nonostante la hash join, la sequenza di queste operazioni rimane meno efficiente rispetto al punto precedente (probabilmente a causa del mancato anticipo della GROUP BY).

# Disabilitare il metodo hash join mediante l'uso di hint (/\*+ NO USE HASH(e d) \*/)

```
SELECT /*+ NO_USE_HASH(e d) */
FROM emp e, dept d
WHERE e.deptno = d.deptno
AND NOT EXISTS
  (SELECT * FROM salgrade WHERE e.sal = hisal);
```



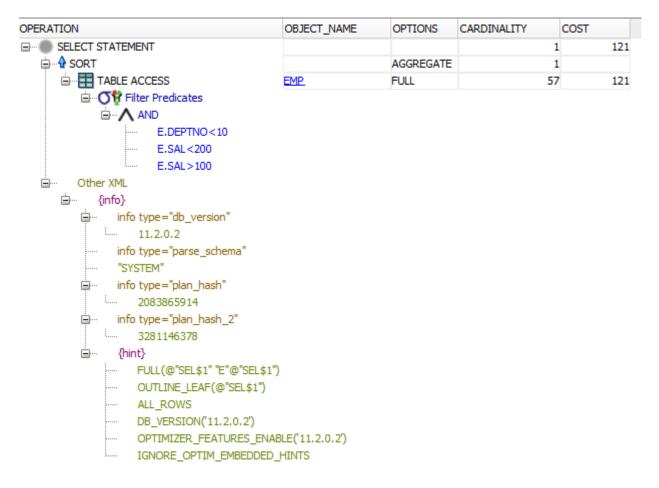
**Nota**. Per scrivere lo schema della query in algebra relazionale, l'operatore "NOT EXISTS" può essere riscritto con una **NOT IN**. Infatti:

```
SELECT ename, job, sal, dname
FROM emp e, dept d
WHERE e.deptno = d.deptno
AND e.sal NOT IN
   (SELECT hisal FROM salgrade);
```

Si definiscano una o più strutture secondarie (indici) che permettano l'ottimizzazione della seguente query. Si analizzi con particolare attenzione il cambiamento nel piano di esecuzione creando due indici sugli attributi interessati dall'interrogazione.

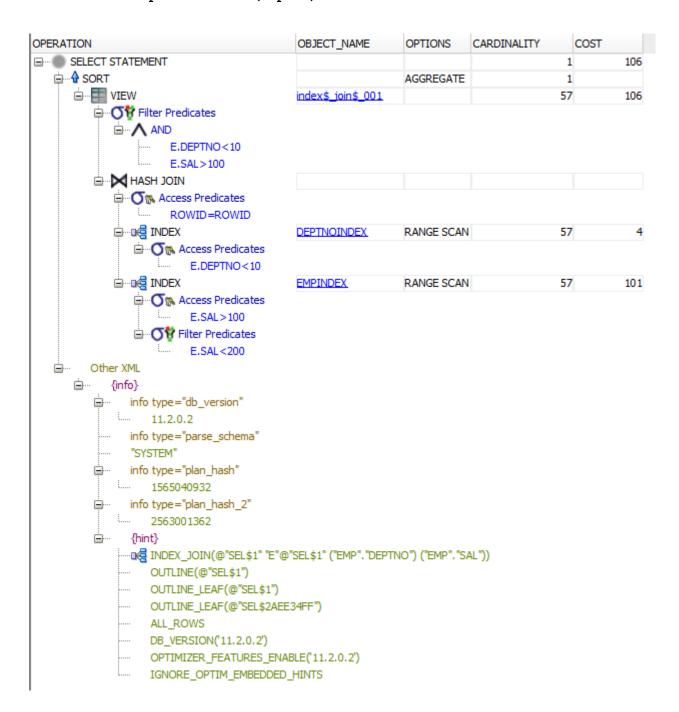
```
select avg(e.sal)
from emp e
where e.deptno < 10 and
e.sal > 100 and e.sal < 200;</pre>
```

### Senza indici:



### Con indici (secondari) su sal e deptno:

```
create index SalIndex on EMP(sal)
create index DepIndex on EMP(deptno)
```

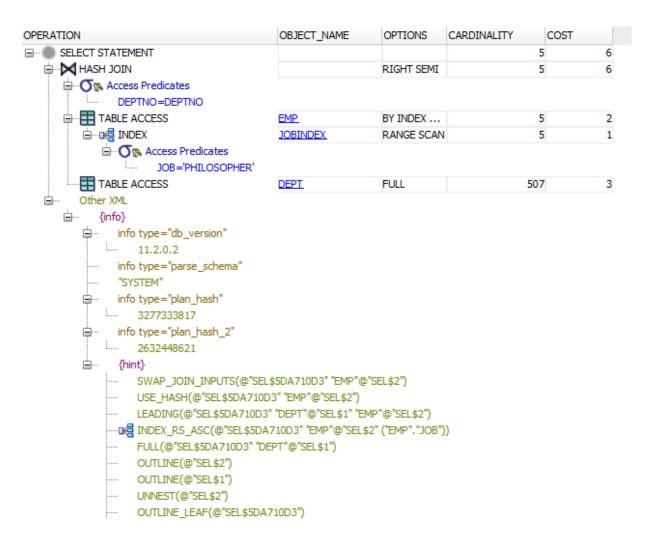


- Gli indici vengono utilizzati per selezionare (access predicates) le righe in base a Sal e Deptno.
- Un access predicate indica, nel caso di un B+Tree index, che i dati vengono selezionati in base ad un certo attributo scendendo nella gerarchia dell'albero (costo logaritmico). Le foglie dell'albero raggruppano i dati in modo

- "grossolano" (=una foglia può contenere molti valori per l'attributo indicizzato).
- Per questo motivo spesso ad un access predicate segue un filter predicate, in cui si analizzano i dati nella foglia dell'albero selezionata. Durante il filter predicate viene quindi eseguito un filtro più fine sui valori dell'attributo. Questa operazione ha costo lineare (tutti i dati nella foglia vengono analizzati).
- In questo esempio il B+Tree viene usato per selezionare Sal>100, poi la ricerca lineare viene usata per selezionare i dati con Sal<200.
- Successivamente viene utilizzato l'indice su DeptNo per selezionare i dipartimenti.
- La Hash Join serve per combinare (tramite row id) i risultati ottenuti filtrando con i due indici (intersezione delle righe che soddisfano le condizioni).
- I filter predicates esterni (deptno<10 e sal>100) vengono infine applicati perché su questi due attributi, nella parte interna della query, è stato eseguito solo un access predicate. Come spiegato in precedenza, un access predicate non è sufficientemente raffinato per selezionare gli esatti valori desiderati, per questo diventa necessario questo ulteriore filter predicate.

Si definiscano una o più strutture secondarie (indici) che permettano l'ottimizzazione della seguente query:

Indice su emp(job), dato che la query interna esegue un filtro su questo attributo. Un ulteriore indice su emp(deptno) non aiuterebbe la join, poiché prima della join viene eseguito un filtro su Job, che richiede l'indice su Job ed un access by row id.



- Il sistema esegue una lettura dell'indice su JOB per filtrare le righe di EMP.
- Successivamente esegue un access by row id (OPTIONS=BY INDEX) per accedere al contenuto degli altri attributi di EMP.
- Infine esegue una hash join con la tabella DEPT

Si definiscano una o più strutture secondarie (indici) che permettano l'ottimizzazione della seguente query (rimuovere eventuali indici già esistenti per confrontare le performance della query con e senza indici):

```
select e1.ename, e1.empno, e1.sal, e2.ename, e2.empno, e2.sal
from emp e1, emp e2
where e1.ename <> e2.ename and e1.sal < e2.sal
and e1.job = 'PHILOSOPHER' and e2.job = 'ENGINEER';</pre>
```

### Indice su emp(job), emp(name) e emp(sal):

